

## <고객관계관리 & 인공지능 보고서>

강의	고객관계관리 & 인공지능
조	11조
이름	고민욱 김주호 배유나 이민혁 장진형 홍성표

## Executive Summary

사회와 기술이 발전함에 따라 방법, 재난 방지용 CCTV는 날이 갈수록 증가하고 있고 소방관들의 처우 개선, 장비 보급 등이 이루어지고 있다. 화재 발생 건수는 감소하는 모습을 보이고 있으나 근본적인 문제인 화재로 인한 재산피해, 인명피해는 감소하지 않고 오히려 증가하는 추세를 보이고 있다. 이에 본 프로젝트에서는 화재로 인한 피해 감소를 위한 혁신적인 주제와 해결 방안에 따라 화재를 감지하는 CCTV와 그에 필요한 기술, 자료 등을 분석했다. 이를 통해 초기 화재 발생시의 빠른 보고와 그에 따른 추가적인 대응의 가속화를 추구하며 발전하는데 시사점을 찾고 방향성을 모색하고자 한다.

### 1) 초기 화재 진압의 혁신 필요성

- 지속적인 국민 소방 교육과 발달한 인터넷 매체들로 인해 화재 발생 시 취해야할 행동을 인지하고 있으나 신속히 행동을 바로 취하지 못하여 화재 진압이 늦어지는 경우도 많음
- 인적이 드문 장소, 부둣가, 산책로 등에서 화재가 발생할 경우, 이를 신고하거나 알아챌 수 있는 사람이 존재하지 않음

### 2) 화재 진압의 주요 요소

- 빠른 화재 진압을 위한 필요 요소로는 즉각적인 신고, 곳곳에 비치된 화재 진압 도구를 이용한 초기 진압, 소방차의 진입로 확보, 시민들의 협조, 소방 시설의 지속적인 유지보수 등이 있음

### 3) 현재 소방 산업의 동향

- 국내 소방방재산업 기술은 일본, 미국 등의 선진국 수준 70~80%정도로 계속해서 국제사회에서의 국가경쟁력이 낮은 수준에 있고, 또한 중국, 인도 등 신흥국에 비해 가격 경쟁력이 약해서 국내 소방산업기반은 미약하게 평가됨
- 해외의 경우, 소방용품만을 전문적으로 생산하는 제조업체와 제조업체의 유형이 많고 그 제품의 품질 또한 우수함. 하지만 국내의 경우, 소방관의 국가직 전환이 최근에 들어서야 이루어지는 등 소방관에 대한 처우 부분부터 부족함

### 4) FBI 프로젝트의 장점 및 문제점

- 기타 다른 프로젝트에 비해 가격 부분에서 강점을 가지고 있고 화재로 인한 피해의 감소에 가장 중요한 골든 타임을 지키는데 중요한 역할을 할 수 있음. 또한 기존의 화재 감지 CCTV에서 일어날 수 있는 열 감지 오류나 연기를 탐지하지 못하는 부분까지 해결이 가능하며 인적이 드문 장소에서의 화재 발생시 CCTV만 설치되어 있다면 소방서에 자동으로 신고가 접수되어 큰 화재로 번지지 않을 가능성이 높음
- 사적공간에 CCTV 설치를 거부한다면 서비스 이용이 불가능하다는 점과 태양, 조명 등 화재 상황과 비슷한 부분을 잘못 인식할 수 있다는 점, 같은 지역 내 다발적인 화재 발생시 대처가 미흡할 수 있다는 점 등의 문제점을 가지고 있음

### 5) 시사점 및 제언

- 초기 화재 진압의 가장 중요한 부분은 골든 타임 내에 소방관의 도착이라고 할 수 있음. 하지만 실제 화재 발생시 당황하여 화재 사실을 은폐하거나 119에 화재 신고가 지연되는 경우, 화재를 인지할 사람이 없을 때 화재가 발생하는 상황이 생길 경우, 이는 대형 화재로 번질 가능성이 높음. 화재로 인한 피해는 물적, 인적 피해가 극심하게 나타나기 때문에 화재에 대한 국민들의 인식 개선과 초기 화재 진압을 수월하게 하기 위한 방안이 필요함

# 목차


I. 대한민국 화재 현황 .....	3
1. 화재 현황 .....	3
1.1. 화재 건수 및 인명·재산 피해 .....	3
1.2. 대형화재로 번질 가능성이 있는 화재 .....	4
2. 골든 타임 .....	4
2.1. 골든 타임이란? .....	4
2.2. 골든 타임 초과 건수 .....	5
II. FBI 프로젝트 .....	5
1. 프로젝트 설명 .....	5
1.1. FBI란? .....	6
1.2. 작동 프로세스 .....	6
1.3. 기대효과 .....	6
2. 장점 및 한계 .....	6
2.1. 장점 .....	6
2.2. 한계 .....	6
III. 모델링 .....	7
1. 모델링 과정 .....	7
1.1. YOLO 모델 .....	7
1.2. Network Modeling .....	8
1.3. Loss Function .....	9
1.3.1. Localization Loss .....	9
1.3.2. Classification Loss .....	9
1.3.3. Confidence Loss .....	10
1.3.4. Final Loss .....	10
2. 구현 단계 .....	11
2.1. 데이터 확보 .....	11
2.1.1. 기존 Dataset .....	11
2.1.2. 사용 Dataset .....	11
2.2. 학습 및 평가 .....	11
2.3. 구현 예시 .....	12
IV. 발전 방향 .....	13
1. 발전 방향 .....	13
1.1. 발전 가능 방향 .....	13
1.2. 근거 .....	13
2. 기대효과 .....	14
V. 결론 .....	15
1. FBI의 의의 .....	15

## 1. 대한민국 화재 현황


### 1. 화재현황

#### 1.1. 화재 건수 및 인명·재산 피해

2009년부터 2018년까지의 화재통계연보를 살펴보면 2018년의 화재발생건수는 약 42,000건으로 약 47,000건이 발생한 2009년에 비해 확실히 감소했지만, 화재로 인한 재산, 인명 피해는 오히려 증가한 통계적 결과를 볼 수 있다. 이는 시간이 지남에 따라 화재 방지 기술은 발전했지만 화재 발생시 시민들의 대응, 초기 화재 진압 방안 등은 전혀 발전되지 않았다는 것을 뜻한다고 할 수 있다. 국민들의 생명, 안전, 재산의 보호 등의 기본권은 반드시 확보되어야 하기 때문에 정부 또는 민간이 나서서 화재 대응 방안을 더욱 발전시키는 일이 필요하다고 판단되었다.



<그림 1> 화재건수 및 인명피해 현황



<그림 2> 화재건수 및 재산피해 현황

## 1.2. 대형화재로 번질 가능성이 있는 화재

처음에 발생한 화재는 그 규모가 크지 않았지만 화재초기 대응미숙, 방화관리 불충분, 화재 진압조건 열악 등의 사유로 대형화재로 발전하기도 한다.

대형화재는 화재사고로 인하여 5명이상 사망하거나 사상자가 10명이상 발생한 경우 또는 재산피해가 50억원 이상 추정되는 경우를 대형화재라고 한다. 화재가 초기에 진압되지 않고 확대되어 대형화재가 된 원인은 주로 다음과 같다.

- 1) 건축물의 유지, 관리가 제대로 되지 않아 화재발생경보 및 화재진압을 위한 소방시설이 기능을 제대로 발휘하지 못한 경우
- 2) 화재발생 사슬을 당황한 나머지 은폐하거나 화재 신고가 지연 또는 화재진압을 위해 필요한 초기 조치가 실패한 경우
- 3) 건축물의 고층화, 지하심층화, 밀집대형화, 가연성 물품 취급 또는 가연성 내장재 사용, 소화활동공간 협소, 고압선, 교통체증 등으로 인한 화재진압환경이 열악한 경우
- 4) 산업시설에서 짙은 연기(유독가스 등), 높은 열을 내뿜는 다량의 가연물을 저장, 취급하여 화재진압이 쉽지 않은 경우

## 2. 골든 타임

### 2.1. 골든 타임이란?


골든 타임은 '금과 같은 시간'을 뜻하는 일본식 영어이다. 미국에선 프라임 타임(Prime Time)이라고 한다. 화재를 포함한 각종 사건, 사고와 재난 현장에선 응급 처치, 인명 구출 및 구조, 화재 진압 등 그 대응의 성패를 좌우하는 초기 시간을 말한다. 소방에서의 골든 타임은 화재가 발생한 건축물의 자재 또는 발화 원인 등을 따져보면 항상 같지는 않겠지만 통상 출동시간 5분+신고접수 2분을 합한 7분이다. 그래야 화재의 초기 진압이 가능하다. 만약 소방관의 골든 타임 내 현장 도착이 불가능하다면 인적, 물적 피해는 걷잡을 수 없이 커지게 된다.



<그림 3> 경과 시간별 화재 단계

## 2.2. 골든 타임 초과 건수

서울시의 통계만 봤을 때, 평균 화재 발생건수는 28,000건, 평균 출동·도착 소요시간은 3분 25초, 평균 화재진압 소요시간은 3분 32초, 평균 사상자 수는 0.044명, 평균 재산 피해는 3,126,000원이다. 통계치의 평균만 보면 골든 타임 및 소방 작업이 잘 진행되고 있는 것으로 보인다. 하지만 연도별 화재 골든 타임 초과 건수를 확인해보면 122건이 발생한 2012년에 비해 2013년에는 172건이 발생했고 2014년에는 163건이 발생했다. 시간이 지남에 따라 인식, 기술 부분에서 발전이 이루어져야 하는데 소방 부분에서는 발전이 이루어지고 있지 않다고 판단된다. 앞서 말한 것과 같이 화재로 인한 피해는 그 물적, 인적 피해가 매우 크고 골든 타임을 놓쳐 대형 화재로 번질 경우, 피해는 견잡을 수 없이 커지게 된다. 이를 방지하고 해결하기 위한 방안의 마련이 시급하다.



<그림 4> 서울시 화재 통계

## II. FBI 프로젝트

### 1. 프로젝트 설명

#### 1.1. FBI란?

'Fire Briefly Inform'의 약어로 '화재를 간략히 보고한다'라는 뜻으로 대한민국 전역에 설치된 CCTV를 통해 화재를 감지하고 예측하는 프로젝트이다. 공공기관 설치 CCTV는 80만대 이상이고 계속 증가하고 있다. 공공기관 이외의 CCTV까지 포함한다면 CCTV가 비추고 있지 않은 지역이 거의 없다고 해도 무방하다. 이런 많은 CCTV를 활용해 초기 화재 대응에 도움을 주고자 한다.

#### 1.2. 작동 프로세스

FBI 프로그램이 내장된 CCTV가 학습된 불, 연기 등의 이미지를 통해 화재를 감지하고 감지된 화면이 인근 소방서로 전송된다. 소방관들은 전송된 화면을 보고 화재 상황인지 판단한다. 화재 상황이라고 판단될 경우, 즉시 출동하여 화재 진압을 실시한다.

#### 1.3. 기대효과

소방관의 입장에서 보면 빠른 화재 초기 진압으로 소방관이랑 직업의 존재 이유인 국민의 생명과 안전을 지키는 일의 완수에 도움을 주는 효과를 줄 수 있고 일반 국민의 입장에서 보면 화재 상황에서의 더 높은 구출, 생존 가능성과 화재로 인한 재산, 인명 피해에 대한 불안감 해소 등이 있다. 또한 사람이 없는 상황에서 작은 불씨로 인해 생길 수 있는 대형 화재 등의 진압이 가능하여 국가적 재산 손실 예방에도 도움이 될 것이다.

### 2. 장점 및 한계

#### 2.1. 장점

- 1) 비용 대비 얻을 수 있는 효과가 큼
- 2) CCTV라는 물적 기반이 이미 확보 되어있음
- 3) 기존 화재 CCTV의 열 감지 오류나 초기 화재의 대부분인 연기를 탐지하지 못한다는 점까지 보완 가능함
- 4) 사람이 거의 지나다니지 않는 한밤중의 시장이나 등산로, 산책로, 부둣가 등에 화재가 발생했을 때, CCTV만 설치되어 있다면 화재 발생 인지 가능

#### 2.2. 한계

- 1) 화재를 잘못 인식할 수 있는 가능성이 있으나 인공지능은 어디까지나 인간을 보조하는 역할을 함으로 최종 판단은 사람이 하기 때문에 문제점 발생 가능성을 낮출 수 있음

- 2) 공공 CCTV가 아닌 사적 CCTV는 활용이 불가능 할 수도 있지만 우선적으로는 공공 CCTV를 사용하고 향후 제도를 통해 의무화된다면 사적 CCTV의 활용도 가능할 것이라 예상
- 3) 같은 지역 내에서 화재가 다발적으로 발생한다면 대응이 힘들다는 한계점이 존재하지만 소방서의 증설과 소방서 내 CCTV 관찰 화면을 증가한다면 보완 가능하다고 봄

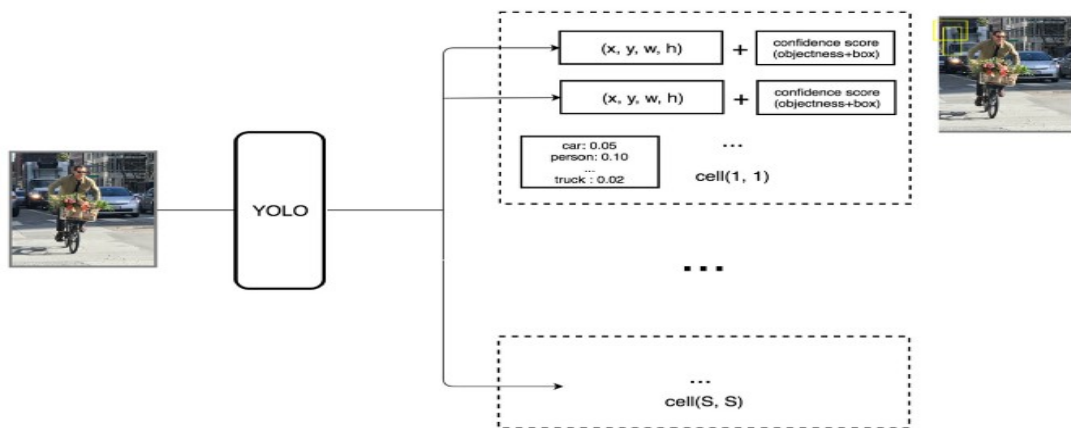
### III. 모델링

#### 1. 모델링 과정

##### 1.1. YOLO 모델

YOLO(You Only Look Once) 모델이란 먼저 간단하게 설명하자면, 예측하고자 하는 이미지를  $S \times S$  Grid Cells로 나누고 각 cell마다 하나의 객체를 예측한다. 그리고 미리 설정된 개수의 boundary boxes를 통해 객체의 위치와 크기를 파악한다. 이때 각 cell마다 하나의 객체만을 예측할 수 있기 때문에 여러 객체가 겹쳐 있으면 몇몇의 객체는 탐지를 못하게 될 수 있다. 그럼 각 cell에서 객체를 예측을 진행하는 조건은 다음과 같다.

- 1) B개의 boundary boxes를 예측하고 각 box는 하나의 box confidence score를 가지고 있다.
- 2) 예측된 box 수에 관계없이 단 하나의 객체만 탐지한다.
- 3) C개의 conditional class probabilities를 예측한다.



<그림 5> YOLO 모델

각 요소를 자세히 살펴보면, 각 boundary box는 객체의 위치 ( $x, y$ ), 객체의 크기 ( $w, h$ ), box confidence score로 구성되어 총 5개의 인자를 가지고 있다. 여기서 box confidence score는 box가 객체를 포함하고 있을 가능성(objectness)과 boundary box가 얼마나 정확한지를 반영한다. Conditional class probabilities는 탐지된 객체가 어느 특정 클래스에 속하는지에 대한 확률이다.



$$\begin{aligned}
\text{box confidence score} &\equiv P_r(\text{object}) \cdot \text{IoU} \\
\text{conditional class probability} &\equiv P_r(\text{class}_i | \text{object}) \\
\text{class confidence score} &\equiv P_r(\text{class}_i) \cdot \text{IoU} \\
&= \text{box confidence score} \times \text{conditional class probability}
\end{aligned}$$

where

$P_r(\text{object})$  is the probability the box contains an object.


$\text{IoU}$  is the IoU (intersection over union) between the predicted box and the ground truth.

$P_r(\text{class}_i | \text{object})$  is the probability the object belongs to  $\text{class}_i$  given an object is presence.

$P_r(\text{class}_i)$  is the probability the object belongs to  $\text{class}_i$

각 score는 수학적으로 위와 같이 정의된다. Class confidence score는 분류와 지역화(localization) 둘 다에 대한 confidence를 측정한다.

## 1.2. Network Modeling



<그림 6> Network Modeling

예를 들어, PASCAL VOC를 평가하기 위해 7x7 grids, 2 boundary boxes, 20 classes를 사용했다고 하자. 그러면 1 cell = 2 x(x, y, w, h, confidence) + 20 = 30 이므로 출력 결과의 형태는 (7,7,30)이 된다. 이제 YOLO의 주요 개념은 (7,7,30) 텐서를 예측하는 CNN 네트워크를 구축하는 것이다. CNN 모델은 spatial dimension을 1024개의 channel을 가진 7x7 dimension으로 줄인다. YOLO는 7x7x2 boundary YOLO는 24개의 convolutional layers와 2개의 fully-connected layers로 구성되어 있다. 몇몇 convolution layers는 1x1 커널을 사용해서 feature maps의 깊이를 줄이고 최종적으로 (7,7,30) 형태의 텐서를 만들어 낸다.

### 1.3 Loss function

#### 1.3.1. localization loss

지역 정규화 손실은 예측된 boundary box의 위치와 크기에 대한 에러를 측정한다.

$$\lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} \left[ (x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right] \\ + \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} \left[ \left( \sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left( \sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \right]$$

where

$\mathbb{1}_{ij}^{\text{obj}} = 1$  if the  $j$ th boundary box in cell  $i$  is responsible for detecting the object, otherwise 0.

$\lambda_{\text{coord}}$  increase the weight for the loss in the boundary box coordinates.

마찬가지로, 객체가 탐지되지 않은 경우에 대해서는 loss 값을 계산하지 않는다.

수식을 살펴보면 위치는 sum squared error를 그대로 적용하지만 크기에 대해서는 각 높이와 너비에 대해 루트 값을 씌워 계산했다. 이렇게 하는 이유는 절대 수치로 계산을 하게 되면 큰 box의 오차가 작은 box의 오차보다 훨씬 큰 가중치를 받게 된다. 예를 들어, 큰 box에서 4 픽셀 에러는 너비가 2 픽셀인 작은 box의 경우와 동일하게 된다. 따라서 YOLO는 bounding box 높이와 너비의 제곱근을 예측하게 된다. 추가적으로, 더 높은 정확도를 위해 coord를 loss에 곱해 가중치를 더 준다.

#### 1.3.2. Classification loss

$$\sum_{i=0}^{S^2} \mathbb{1}_i^{\text{obj}} \sum_{c \in \text{classes}} (p_i(c) - \hat{p}_i(c))^2$$

where

$\mathbb{1}_i^{\text{obj}} = 1$  if an object appears in cell  $i$ , otherwise 0.

$\hat{p}_i(c)$  denotes the conditional class probability for class  $c$  in cell  $i$ .

객체가 탐지되었다면, 각 cell classification loss는 각 클래스의 class conditional probabilities의 squared error다. 위에 수식에서 볼 수 있듯이 객체가 탐지되지 않았다면 0이 된다.

### 1.3.3 Confidence loss

$$\sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{obj} (C_i - \hat{C}_i)^2$$

where

$\hat{C}_i$  is the box confidence score of the box  $j$  in cell  $i$ .

$\mathbb{1}_{ij}^{obj} = 1$  if the  $j$  th boundary box in cell  $i$  is responsible for detecting the object, otherwise 0.

객체가 탐지되지 않은 경우는 loss function은 아래와 같다.

$$\lambda_{noobj} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{noobj} (C_i - \hat{C}_i)^2$$

where

$\mathbb{1}_{ij}^{noobj}$  is the complement of  $\mathbb{1}_{ij}^{obj}$ .

$\hat{C}_i$  is the box confidence score of the box  $j$  in cell  $i$ .

$\lambda_{noobj}$  weights down the loss when detecting background.

둘 다 다른 점은 객체가 탐지되지 않은 경우는 noobj(default:0.5)에 의해 loss 의 가중을 적게 한다는 점이다. 이렇게 하는 이유는 클래스 불균형 문제를 방지하기 위함이다. 사실 대부분의 box 가 객체를 포함하고 있지 않은 경우가 더 많기 때문에 배경에 대한 가중을 줄이지 않는 경우 배경을 탐지하는 모델로 훈련될 수 있다.

### 1.3.4. Final Loss

최종 loss 는 위의 모든 loss 를 더한 것이다

$$\begin{aligned} & \lambda_{coord} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{obj} \left[ (x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right] \\ & + \lambda_{coord} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{obj} \left[ \left( \sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left( \sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \right] \\ & + \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{obj} (C_i - \hat{C}_i)^2 \\ & + \lambda_{noobj} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{noobj} (C_i - \hat{C}_i)^2 \\ & + \sum_{i=0}^{S^2} \mathbb{1}_i^{obj} \sum_{c \in \text{classes}} (p_i(c) - \hat{p}_i(c))^2 \end{aligned}$$

## 2. 구현 단계

### 2.1. 데이터 확보

#### 2.1.1. 기존 Dataset

화재 관련 선행 연구들은 대부분 MNIVA Fire Dataset을 이용해 모델링 했는데, 이를 얻기 위해서는 메일을 보내는 등의 요청 과정이 필요했다. 본 연구도 메일을 보냈으나, 답장이 오지 않았고 시간이 한정되어 있어 마냥 기다릴 수 없어 요청 과정을 생략하고 연구를 진행했다.

#### 2.1.2. 사용 DataSet

위와 같은 이유 때문에, 유튜브, 구글 등을 통해 사진을 직접 수집했고, 조원들이 힘을 합쳐 수작업으로 Bound Box를 설정했다.

이 과정을 통해 완성된 Dataset은 다음과 같다.

- 1) 불, 연기 Class 가 존재하는 사진 약 5000장 + Bound Box의 좌표 값
  - 2) 불로 오해할 수 있는 (불빛 Class) 사진 약 1000장 + Bound Box의 좌표 값
- 이를 85:15의 비율로 train과 valid로 나누어 학습을 진행했다.

### 2.2. 학습 및 평가

#### 1. 환경

Yolo v3가 빌드 되어있는 Darknet이 C, CUDA , Linux 기반이라, 패키지 버전문제와, Linux 커맨드를 이용할 수 있는 Google Colab 에서 학습을 진행했다.

#### 2. 파라미터

사용한 파라미터는 다음과 같다.

Batch size = 64, max\_batches = 6000, classes = 80 , filters = 24

#### 3. 성능 지표

60~70 epoch일 때 최적의 로스를 보였고, 그때의 성능지표는 다음과 같다.

- 1) Avg loss = 0.66
- 2) Fire class의 ap = 86.47 %
- 3) Smoke class의 ap = 80.54 %
- 4) Light class 의 ap 62.49 %  
(False case 인데다, Fire와 매우 특성이 유사해 FP가 매우 많았다.)
- 5) mAP : 76.5 %

```

detections_count = 64729, unique_truth_count = 11503
class_id = 0, name = fire, ap = 86.47%      (TP = 4135, FP = 922)
class_id = 1, name = smoke, ap = 80.54%     (TP = 2241, FP = 382)
class_id = 2, name = light, ap = 62.49%     (TP = 2161, FP = 1504)

for conf_thresh = 0.25, precision = 0.75, recall = 0.74, F1-score = 0.75
for conf_thresh = 0.25, TP = 8537, FP = 2808, FN = 2966, average IoU = 55.63 %

IoU threshold = 50 %, used Area-Under-Curve for each unique Recall
mean average precision (mAP@0.50) = 0.764982, or 76.50 %
Total Detection Time: 43.000000 Seconds

```

<그림 7> 성능지표

### 2.3. 구현 예시



<그림 8> 구현 예시

그림 1,2를 통해 화재와 연기가 어떤 식으로 검출되는지 확인할 수 있으며  
그림 3과 같은 사진으로는 구분하기 힘든 밝은 불빛도 구분해 낼 수 있다.

#### IV. 발전 방향

### 1. 발전 방향

#### 1.1. 발전 가능 방향

향후 공공, 사적 CCTV 뿐만 아니라 차량에 설치된 블랙 박스에도 FBI 프로그램을 탑재하여 화재 탐지를 한다면 CCTV가 비출 수 없는 공간에서 일어나는 화재까지도 탐지가 가능하여 궁극적으로는 화재 피해 없는 나라가 될 수 있을 것이라고 생각한다.




<그림 9> 블랙박스 예시

#### 1.2. 근거

가격비교 사이트인 '다나와'와 메리츠종금증권 리서치센터에 의하면 2016년, 국내 블랙박스 시장 규모가 약 200만대에 이르렀고 지속적으로 증가하는 추세를 보인다. 2019년 현재는 약 300만대 이상으로 추정된다. 또한 2019년 기준, 차량용 블랙박스의 장착유무 조사에 따르면 블랙박스를 장착한 경우가 88.9%로 매우 높은 비율을 보여주고 있다. 자가 차량을 구매하는 사람들이 늘어나고 그에 따라 블랙박스는 필수로 장착해야 되는 품목이 되면서 블랙박스의 수요 또한 늘어나고 있다. 이에 따라 FBI 프로그램이 모든 차량의 블랙박스에 탑재된다면 앞서 말했던 대형 화재가 일어날 수 없는 환경이 조성될 것이라고 전망된다.

그림3 국내 블랙박스 시장



<그림 10> 국내 블랙박스 시장



<그림 11> 차량용 블랙박스 장착 유무 통계

## 2. 기대효과

- 1) 차량에 설치된 블랙박스에 FBI 프로그램을 탑재하여 CCTV가 설치되지 않은 장소까지 감지 가능
- 2) 현재 약 300만대 이상의 블랙박스가 존재하기 때문에 훨씬 더 향상된 화재 감지가 가능
- 3) 화재 탐지 뿐만 아니라 방범용으로도 사용된다면 더욱 큰 효과를 얻을 수 있을 것이라고 예상

## V. 결론

---

### 1. FBI 프로젝트의 의의

- 1) FBI(Fire Briefly Inform) 프로젝트는 CCTV에 프로그램을 탑재해 학습된 이미지를 기반으로 초기 화재를 감지, 소방서에 자동으로 신고하는 시스템
- 2) 화재발생건수는 줄고 있지만 근본적인 문제인 화재로 인한 재산, 인명 피해는 오히려 증가하는 추세이며 이를 해결하기 위한 방안이 필요하다고 판단
- 3) 화재 현장에서의 응급 처치, 인명 구출 및 구조, 화재 진압 등 그 대응의 성패를 좌우하는 초기 시간을 골든 타임이라고 말하는데, 이 골든 타임이 지켜지지 않아 큰 물적, 인적 피해를 입는 경우의 수가 무시 못할 수준. 대표적인 이유로는 화재가 생겼을 때 당황하거나 신고를 할 수 있는 상황이 아니어서 화재 신고가 지연되는 경우, 인적이 드문 곳에 화재가 발생하여 이미 대형 화재로 번진 이후에 소방관이 출동하는 경우 등이 있음. 이를 해결하기 위한 방안이 FBI 프로젝트
- 4) FBI가 작동하는 프로세스는 다음과 같음.  
프로그램이 내장된 CCTV가 화재를 감지 → 인근 소방서로 화면 전송 → 소방관들은 전송된 화면을 보고 화재가 발생한 건지 판단 → 화재가 발생했다고 판단된 경우, 즉시 현장으로 출동
- 5) YOLO 모델을 사용, cell 객체 예측과 단계별 Loss Function을 통해 모델링을 진행
- 6) 궁극적인 목표로는 공공, 사적 CCTV 모두에 프로그램 탑재, 이를 위해서는 정부의 FBI 프로그램 탑재 의무 제도가 필요
- 7) 향후 발전 방향으로 FBI 프로그램을 차량용 블랙박스에 탑재, 더 많은 화재 감지가 이루어질 수 있을 것이라는 기대효과 존재